

Оптимизация агентных способностей Qwen 2.5 (0.5B) с помощью SFT и GRPO

1 Постановка задачи

Цель проекта — обучить ультракомпактную языковую модель (0.5B параметров) решать сложную алгоритмическую задачу поиска пути в графе.

Агент должен проанализировать условия (матрицу смежности, стартовый и конечный узлы), построить цепочку рассуждений и выдать итоговый маршрут в строгом XML-формате: сначала процесс принятия решений в тегах `<reasoning>`, затем итоговая последовательность узлов в тегах `<answer>`.

2 Проводимые эксперименты

Для выявления оптимальной стратегии обучения (Alignment) компактной модели были протестированы методы Supervised Fine-Tuning (SFT) и Group Relative Policy Optimization (GRPO). Базовая модель: `unsloth/Qwen2.5-0.5B-Instruct`.

Оценка проводилась на отложенном хард-датасете `hard_val_128` в режиме быстрого инференса (`pass@1`, жадная генерация, батч 8). Архитектура экспериментов разделена на 5 последовательных шагов:

Шаг по ДЗ	Название эксперимента	Датасет для обучения	Датасет для валидации	Описание процесса
Шаг 1	Baseline оценка	Обучение не проводится	val и Hard-val	Замеряем <code>pass@k</code> и длину генерации на базовой модели Qwen2.5-0.5B-Instruct без дообучения. Доказываем, что на Hard-val <code>pass@128=0</code> .
Шаг 2	GRPO-only (без gold)	<code>curriculum+hard_train.pkl</code> (стандартный, без золотых траекторий)	val и Hard-val	Обучаем базовую модель только с помощью Curriculum GRPO и reward-функции через верификатор.
Шаг 3.1	SFT-only (Опционально)	<code>gold_train_128.pkl</code> (только собранные gold trajectories)	val и Hard-val	Обучаем базовую модель классическим Supervised Fine-Tuning на эталонных решениях. В задании сказано, что это полезно для декомпозиции эффектов.

Шаг по ДЗ	Название эксперимента	Датасет для обучения	Датасет для валидации	Описание процесса
Шаг 3.2	SFT \$\\rightarrow\$ GRPO	curriculum+hard_train.pkl (с reward-функцией)	val и Hard-val	Берем веса модели, получившиеся на шаге 3.1 (после SFT), и дообучаем их с помощью Curriculum GRPO.
Шаг 4	SRFT (Выбранный метод)	curriculum+gold_train.pkl (смесь on-policy генераций и gold trajectories)	val и Hard-val	Берем базовую модель (Baseline) и обучаем её гибридным методом, совмещаая SFT-сигнал и RL-награды в одном цикле обучения.

3 Результаты

Эксперимент выявил фундаментальную разницу во влиянии SFT и GRPO на логику модели. В то время как SFT обеспечил радикальный рост всех метрик при генерации первого ответа (**pass@1**), внедрение GRPO спровоцировало эффект "длинных раздумий", но привело к резкому росту галлюцинаций.

Сводная таблица результатов (на датасете `hard_val_128`, **pass@1**):

Метрика	Baseline (0.5B)	GRPO Only	SFT Only	SFT + GRPO	SRFT (Финальная)
Accuracy (Найден корректный путь)	0.0%	8.6%	90.6%	1.6%	18.8%
Optimal Rate / pass@1 (Найден абсолютно оптимальный путь)	0.0%	6.3%	25.8%	1.6%	13.3%
Format Compliance (Соблюдение XML-разметки)	3.1%	70.3%	97.7%	1.6%	82.8%
Hallucination Rate (Построение пути по несуществующим ребрам)	3.1%	56.3%	6.3%	0.0%	58.6%
Optimality Gap (Штраф за неоптимальность маршрута)	0.00	0.91	6.35	0.00	1.29
Reasoning Len (Среднее число токенов в блоке рассуждений)	24	523	483	13	869

Ключевые выводы:

- **Триумф чистого SFT в pass@1:** Обучение с учителем (**SFT Only**) показало феноменальные результаты для «жадной» генерации. Модель научилась идеально соблюдать формат (97.7%) и доводить агента до цели в 90.6% случаев. Галлюцинации составили минимальные 6.3%. Модель уверенно выучила структуру графов из тренировочной выборки.
- **Галлюцинации при GRPO:** Попытка обучать модель через систему наград (**GRPO Only** и **SRFT Model**) привела к тому, что агент начал массово "срезать углы". Уровень галлюцинаций подскочил до 56-58% — модель строит пути там, где нет физических ребер графа, пытаясь обмануть метрику (Reward Hacking).
- **Эффект "Длинных раздумий" (Chain-of-Thought):** Финальная модель (**SRFT**) продемонстрировала классическое поведение RL-политики. Она генерирует почти 869 токенов в блоке `<reasoning>`. Модель усвоила, что длинная цепочка мыслей потенциально ведет к награде, поэтому "думает" дольше всех, даже если в итоге ошибается.
- **Коллапс при неудачном слиянии:** Конфигурация **SFT + GRPO** пережила катастрофическое забывание. Веса разрушились, и модель откатилась к состоянию хуже базовой: полное непонимание формата (1.6%) и отказ от рассуждений (всего 13 токенов).

Итог: Для малогабаритных моделей (0.5B) классический SFT является наиболее стабильным и надежным методом усвоения алгоритмической логики при лобовом тестировании (**pass@1**). Внедрение GRPO наделяет агента способностью к глубоким рассуждениям (увеличение контекста размышлений), однако без жестких штрафов за невалидные переходы RLHF-алгоритм быстро деградирует в галлюцинации. Для раскрытия истинного потенциала финальной SRFT-модели с её длинными размышлениями

требуется замер метрики **pass@128** (сэмплирование с температурой), где вариативность её ответов может превзойти детерминированность SFT-модели.

Эволюция метрик LLM-агента на датасете **hard_val_128**



