


Learning from "Unsolvable" Tasks (RL + Supervised Signal)



ИЗБРАННЫЕ ТЕМЫ ИССЛЕДОВАНИЙ В AI

ДОМАШНЕЕ ЗАДАНИЕ

НЕДЕЛЯ 3

1. ЦЕЛЬ

Обучить LLM решать класс задач, которые в **baseline** модель не решает вообще.

Критерий «нерешаемости»: на фиксированном подмножестве задач (**Hard subset**) модель имеет **pass@128 = 0** (то есть среди 128 независимых сэмплов не находится ни одного корректного решения).

Ваша задача — добиться, чтобы после обучения на этом же Hard subset было **pass@128 > 0** (лучше — заметно > 0), и показать это экспериментально.

2. ЧТО НУЖНО РЕАЛИЗОВАТЬ

Выберите **один метод** (можно больше — это плюс, но не обязательно):

- [LUFFY](#)
- [RL-PLUS](#)
- [SRFT](#)

3. ДАННЫЕ/СРЕДА И "GOLD TRAJECTORIES"

Вам нужны задачи, где:

1. есть **верифицируемая** проверка корректности (желательно программная),
2. можно получить **правильные траектории/решения** (gold).

Выберите один источник.

Вариант А: ваша среда из Д32 (рекомендуется)

1. Берёте свою среду из Д32.
2. Подбираете сложность/гиперпараметры так, чтобы для **Qwen2.5-0.5B-Instruct** существовал **Hard subset**, на котором **baseline pass@128 = 0**:
 - **Hard-train** $\subset$ train
 - **Hard-val** $\subset$ val

ВАЖНО

pass@128=0 требуется именно на hard subset'ах, а не на всём train/val (иначе RL вообще может не взлететь или будет слишком «мертвый» сигнал).

3. Получаете **gold trajectories**:
 - либо более сильной моделью (larger open-source / API — на ваш выбор),
 - либо любым другим способом,
 - но каждую gold-траекторию нужно **проверять** вашим **verifier'ом**.

Вариант В: готовый датасет с траекториями

Можно взять датасет, где есть «задача → рассуждение/решение → ответ» (например [OpenThoughts-114k](#)).

Требования:

- траектория **влезает** в контекст и память при обучении,
- корректность **верифицируема** (идеально — скриптом; если нет — объясните выбранный способ верификации и почему он приемлем),
- вы явно формируете **Hard subset** по baseline pass@128=0.

4. МОДЕЛЬ, ФОРМАТ ВЫВОДА, ИНФЕРЕНС-ПАРАМЕТРЫ

Рекомендуемая модель: **Qwen/Qwen2.5-0.5B-Instruct** (можно больше, если позволяют ресурсы).

Можно использовать:

- unsloth/LoRA
- vLLM для быстрого инференса при pass@k

Один фиксированный system prompt для всех сравнений (baseline и все обученные варианты).

Если математика:

```
You are helpful assistant. Please reason step by step, and put
your final answer within \boxed{}
```

Если общая задача с вашим верификатором:.

```
You are a helpful assistant. You always first think about the
reasoning process in the mind and then provides the user with
the answer.\n\nThe reasoning process and answer are enclosed
within '<think>' '</think>' and '<answer>' '</answer>' tags,
respectively, e.g.,\n\n<think>\nA detailed reasoning process here,
with possible reflections including but not limited to reviewing
previous steps for errors, exploring alternative approaches, and
considering possible refinements.\n</think>\n<answer>\nReply to
user here.\n</answer>. Please reason step by step, and put your
final answer within <answer> </answer> tags.
```

Важно: в отчёте зафиксируйте единые параметры генерации для всех сравнений:

- temperature
- top_p (или top_k)
- max_tokens

5. РАЗБИЕНИЕ ДАННЫХ

Данные делятся на **train / val**.

Требования к воспроизводимости:

- **val** фиксированная.
- Вы явно выделяете:
 - **Hard-train**: подмножество train, где baseline pass@128=0
 - **Hard-val**: подмножество val, где baseline pass@128=0

На практике удобно держать ещё и "Mixed" (где что-то решается), но hard subset обязателен.

6. МЕТРИКИ

Основная метрика: **pass@k** на **val**, отдельно на **Hard-val**.

$$\text{pass@k} = 1 - \frac{\binom{n-c}{k}}{\binom{n}{k}}$$

- Для каждого задания делаете n независимых сэмплов (например $n=128$).
- Считаете **pass@k** ($k \leq n$). Можно показывать кривые **pass@k** для нескольких k (например 1, 4, 8, 16, 32, 64, 128).

Дополнительно:

- динамика reward (train),
- энтропия
- средняя длина генерации,

7. ЭКСПЕРИМЕНТАЛЬНЫЙ ПРОТОКОЛ

Шаг 0. Подготовка данных

- Сформируйте train/val и hard subset'ы.
- Докажите, что baseline действительно даёт **pass@128=0** на Hard-train и Hard-val (табличкой/логами).

Шаг 1. Baseline оценка

На **val** и **Hard-val** измерьте:

- **pass@k** (желательно кривая до 128, либо до 64 при ограничениях),
- среднюю длину генерации,

Шаг 2. GRPO-only (reward-only, без gold)

Обучите на train с GRPO, используя только reward через verifier, **без** правильных траекторий.

Логируйте:

- reward curve,
- энтропию,
- длину генераций.

Оцените на val/Hard-val: pass@k и длины.

Шаг 3. SFT → GRPO (используя gold)

1. SFT на gold trajectories (train).
2. Затем GRPO (train) с тем же reward.

Сравните с шагом 2:

- pass@k на val/Hard-val,
- динамика reward,
- энтропия,
- длина генераций.

Если хотите — добавьте отдельную оценку "SFT-only", это полезно для декомпозиции эффектов.

Шаг 4. Выбранный метод (LUFFY / RL-PLUS / SRFT)

Реализуйте выбранный метод так, как он предполагает совмещение:

- on-policy генераций модели,
- и gold trajectories / supervised сигнала.

Сравнение минимум с:

- baseline,
- GRPO-only,
- SFT-only (если делали),
- SFT → GRPO.

8. ЧТО ДОЛЖНО БЫТЬ В ОТЧЁТЕ

Обязательное:

1. Качество (главное сравнение)

- Графики **pass@k** ($k=1...128$ или до 64) на:
 - val (full)
 - Hard-val
- Сравнить минимум 3 модели: **baseline**, **GRPO-only**, **SFT → GRPO** и ваш метод (LUFFY/RL-PLUS/SRFT).

2. Динамика во время обучения

- Графики по шагам обучения: **reward curve**, длина генераций.
- Энтропия (если хватает ресурсов)

3. Сломали ли "ноль"?

Явно показать, получилось ли **pass@128** на **Hard-val**: **0** → **> 0** после обучения.

4. Длина генераций

Средняя/медианная длина (tokens) на **val** и **Hard-val**: baseline vs обученные.

5. Trade-off качество vs diversity

- Ответить: **падает ли pass@k на val (full)** по сравнению с baseline после RL?
- Если падает — как сильно и почему вы думаете, что так произошло.